



Taller de Ciencia de Datos: Árboles de Decisión

De la teoría del Machine Learning a la predicción de riesgo cardíaco con Scikit-Learn.



Las máquinas ya no se programan con reglas estáticas; aprenden de su entorno.



Ajuste de Mercado

Un modelo analiza en milisegundos la oferta (conductores), la demanda (usuarios), el clima y el tráfico para ajustar los precios al instante y equilibrar el mercado.



Análisis de Sentimiento
Me siento cansado...

Traducción Automática
Traducción Tabla...

Contexto Cultural
Contexto Cultural

Entidades Nombradas
La zona de la...

Intención del Usuario
Interactúa ses...

Comprensión Contextual

Al leer de forma masiva en internet, el modelo traduce basándose en el contexto global de la frase, generando un lenguaje natural en lugar de de una traducción literal automatizada.

El patrón universal detrás de cada decisión automatizada.




Datos de Entrada

La materia prima empírica que alimenta al sistema.



Entrenamiento

La máquina busca matemáticamente patrones ocultos y relaciones entre los datos y un resultado conocido.



Predicción

Al recibir datos nuevos y desconocidos, la máquina infiere el desenlace con alta precisión.

La anatomía de una predicción: Ingredientes, Receta y Resultado.

Los Ingredientes




La Receta



El Pastel




Los Datos




Los componentes crudos. El mundo real documentado en números, texto o imágenes.

El Algoritmo



Los pasos lógicos y matemáticos genéricos. La estructura base sin adaptar.

El Modelo



El objetivo terminado. Una simplificación matemática que retiene los patrones clave de la realidad.

El ciclo de entrenamiento requiere datos, repetición sistemática y corrección.

1. Recopilación y Limpieza

Los datos crudos suelen estar incompletos o erróneos. Regla de oro: Garbage in, Garbage out (si entra basura, sale basura).

2. Elección del Algoritmo

Selección del cerebro matemático adecuado: una Red Neuronal, una Regresión, o un Árbol de Decisión.


4. Validación y Testeo

Pruebas con datos nuevos para confirmar que el modelo aprendió reglas generales y no solo memorizó respuestas (Overfitting).

3. Iteración y Ajuste

Bucle matemático:
1. Predicción inicial.
2. Cálculo del error.
3. Ajuste de parámetros para reducir el error en el próximo intento.

Modelos Supervisados: Aprendiendo de un profesor con las respuestas correctas.




Clasificación (Nuestro enfoque)



Predice clases discretas y categóricas
(ej. Spam / No Spam, Riesgo Benigno / Maligno).

Regresión



Predice valores numéricos continuos a lo largo del tiempo
(ej. Precio del dólar, Temperatura, Volumen de Ventas).

El Árbol de Decisión descarta opciones mediante preguntas binarias secuenciales.



El algoritmo funciona bajo la misma lógica: segmenta la información realizando preguntas de Sí o No repetidamente hasta aislar la respuesta correcta en el nodo final.


La anatomía estructural de un Árbol de Decisión.

Nodo Raíz: La primera pregunta que divide la totalidad del conjunto de datos.

Nodo Interno: Preguntas intermedias que continúan refinando la división.


Rama: El camino condicional lógico tomado, basado en un flujo binario.

Hoja (Nodo Terminal): La decisión final o la clase definitiva predicha por el modelo.




Profundidad: La cantidad de niveles de preguntas desde la raíz hasta la hoja.

Impureza Gini: La brújula matemática para elegir la mejor pregunta.



Separación Pobre (Alta Impureza)

La pregunta no logró aislar los datos de manera efectiva. El resultado es un conjunto altamente mezclado e incierto.



Separación Pura (Baja Impureza)

La pregunta dividió los datos de forma matemática perfecta, clasificándolos con absoluta certeza.

¿Cómo elige el árbol? Prueba cientos de cortes matemáticos y siempre selecciona la pregunta que deje los datos resultantes más puros, minimizando la Impureza Gini.

El Reto Clínico: Predecir el riesgo cardíaco a través de datos biométricos.

0
(No presenta riesgo)



1
(Presenta riesgo)

Variable Objetivo



Edad



Presión Arterial



Nivel Glucosa



Colesterol



Índice Masa Corporal



Frecuencia Cardíaca



Horas de Sueño



Actividad Física



Nivel Estrés



O₂ Oxigenación Sangre



Regla 1:

Si Nivel Glucosa es ALTO y Colesterol es ALTO (1)



Regla 2:

Si Actividad Física es ALTA y Nivel Estrés es BAJO = Menor Riesgo (0)

Implementación [1/3]: Preparando el escenario y aislando el examen final.


```
X = df.drop("riesgo_cardiaco", axis=1)  
y = df["riesgo_cardiaco"]
```

```
X_train, X_test, y_train, y_test =  
train_test_split(X, y, test_size=0.3,  
random_state=42)
```

Variables
Predictoras
(X)

Respuesta
Clínica (y)


70%
Entrenamiento:
Para que el modelo
estudie y encuentre
patrones lógicos.




30%
Examen Final:
Se esconde para
probar la precisión
del modelo al final.

Implementación [2/3]: Definiendo las reglas y entrenando el cerebro matemático.

```
modelo = DecisionTreeClassifier(  
    criterion="gini",  
    max_depth=3, random_state=42)  
  
modelo.fit(X_train, y_train)
```




Limitamos el árbol a 3 niveles de profundidad para evitar un modelo excesivamente complejo que solo memorice.




El Entrenamiento (fit):
El momento donde la máquina analiza los historiales médicos para descubrir de forma autónoma los patrones lógicos del riesgo cardíaco.

Implementación [3/3]: El examen final y la boleta de calificaciones.

```
y_pred = modelo.predict(X_test)
print(accuracy_score(y_test, y_pred))
```



El paisaje completo: Del caos de los datos a la claridad predictiva.



El Machine Learning no es magia; es la transformación rigurosa del historial médico en reglas lógicas, matemáticas y automatizables que pueden anticipar riesgos de salud reales.

El modelo está listo. Es hora de inspeccionar cómo piensa la máquina.

Hemos configurado las variables, entrenado el modelo matemático y comprobado su precisión analítica. El siguiente paso práctico es explorar su estructura lógica interna.

Abre el cuaderno `visualización_resultados.ipynb` en tu entorno local para inspeccionar detalladamente cada rama, nodo y decisión que ha tomado nuestro modelo clínico.

